

Graf Tabanlı Anomali Tespiti ile Oltalama (Phishing) Web Sitesi Tanımlama

1. Proje Amacı (Goal)

Bu projenin temel amacı, web sitelerinin yapısal ve ilişkisel özelliklerini analiz ederek "Oltalama" (Phishing) saldırılarını tespit etmek için geleneksel Makine Öğrenmesi (ML) yöntemleri ile Graf tabanlı (Graph-based) yaklaşımları karşılaştırmaktır. Proje kapsamında, daha önce eğitilen geleneksel modellerin üzerine, URL yapıları ve site özellikleri arasındaki ilişkileri modelleyen yeni nesil graf metotları eklenecek ve sonuçlar kıyaslanacaktır.

2. Veri Setleri (Datasets)

Projede ana odak noktası olarak oltalama saldırılarını içeren kapsamlı veri setleri kullanılacaktır:

- Phishing Websites Dataset:** Kaggle üzerinde yer alan ve URL uzunluğu, SSL sertifika durumu, yönlendirme (redirection) sayıları ve HTTPS kullanımı gibi 30'a yakın teknik öznitelik barındıran veri seti ana kaynak olacaktır.
- Etiketleme:** Veriler, sitenin gerçek durumuna göre "Güvenli" (0) veya "Oltalama" (1) olarak ikili sınıflandırma (binary classification) formatında etiketlenecektir.
- Doğrulama Kaynakları:** Modelin güncelliğini test etmek amacıyla gerekirse PhishTank gibi açık kaynaklı oltalama veri tabanlarından ek veriler çekilecektir.

3. Graf Modelleme (Graph Modeling)

Web siteleri ve özellikleri arasındaki ilişkiler bir ağ yapısı olarak temsil edilecektir:

- Heterojen Graf Yapısı:** Web siteleri, IP adresleri, SSL sağlayıcıları ve alan adları (domain) düğüm (node) olarak temsil edilecektir.
- Kenar İlişkileri (Edges):** Aynı IP üzerinden sunulan siteler, benzer SSL sertifikasına sahip alan adları veya aynı anahtar kelimeleri paylaşan URL'ler arasında bağlantılar kurulacaktır.
- Düğüm Özellikleri:** URL içindeki özel karakter sayısı, alan adı yaşı ve yönlendirme trafiği gibi istatistikler düğüm öznitelikleri olarak atanacaktır.
- Yapısal Metrikler:** Graf üzerinden derece merkeziliği ve kümelenme katsayısı gibi özellikler hesaplanarak oltalama sitelerinin ağ içindeki yapısal konumları belirlenecektir.

4. Metodoloji (Methodology)

Proje, graf yapısı içindeki yapısal anomalileri tespit etmeye odaklanacaktır:

- Normal bir web sitesi ağ yapısından belirgin şekilde sapan (örneğin; çok kısa sürede oluşturulmuş ve izole bağlantılara sahip) siteler potansiyel oltalama adayı olarak değerlendirilecektir.

- Hesaplanan graf metrikleri birer öznitelik vektörü olarak kullanılacak ve **Isolation Forest**, **Local Outlier Factor (LOF)** ve **One-Class SVM** gibi anomali tespit algoritmaları ile analiz edilecektir.
- Hedef, ortalama sitelerinin graf yapısı içerisinde yapısal olarak "ayrıt edici" (structurally distinct) pozisyonlarda olup olmadığını kanıtlamaktır.

5. Beklenen Çıktılar (Expected Outcome)

Proje sonunda, graf tabanlı analizlerin sadece metin tabanlı analizlere göre ortalama tespitinde çok daha yüksek başarı sağladığı gösterilecektir. Ortalama sitelerinin, genellikle normal sitelerden farklı bağlantı örüntüleri (anormal merkezîyet puanları veya izole alt gruplar gibi) sergilemesi beklenmektedir. Bu sonuçlar, siber güvenlik dünyasında graf teorisinin dolandırıcılık tespitindeki kritik önemini ortaya koyacaktır.

Kaynaklar

<https://github.com/cihanut/PhishingTest>

https://raw.githubusercontent.com/openphish/public_feed/refs/heads/main/feed.txt

https://www.phishtank.com/developer_info.php

<https://www.kaggle.com/datasets/akashkr/phishing-website-dataset>